

대전시 공공 대기질 자료를 활용한 미세먼지 예측, 공간 취약성 진단 및 2026 년 근미래 시나리오 분석

공공 관측자료 기반 시계열 예측공간 취약성근미래 시나리오 통합 스터디

이청빈

대전대학교 토목환경공학부 졸업

2025-12-02

차 례

목차

국문 요약

1. 서론

- 1.1 연구 배경 및 필요성
- 1.2 선행연구 동향
- 1.3 연구 공백
- 1.4 연구 목적 및 연구 질문

2. 연구 대상 지역 및 데이터

- 2.1 연구 대상 지역
- 2.2 대기질 데이터
- 2.3 기상 데이터
- 2.4 지역 PM 경보 및 황사 경보
- 2.5 파생 데이터 테이블

3. 연구

- 3.1 Overall workflow
- 3.2 Data processing
- 3.3 Feature engineering
- 3.4 Machine learning models

3.5 Spatial analysis with QGIS

3.6 Summary statistics & Power BI dashboards

3.7 Multi-analog scenario 2026 & ensemble risk

4. 결과

4.1 RQ1 - 1hour-ahead prediction performance

4.2 RQ2 - Spatial vulnerability in 2021 - 2023

4.3 2026 multi-analog scenarios & ensemble risk

5. 논의

5.1 Predictive capability and limitations

5.2 Spatial vulnerability and policy implications

5.3 Strengths, limitations and future work

6. 결론

참고문헌

영문 요약

국 문 요 약

대전시 공공 대기질 자료를 활용한 1 시간 뒤 미세먼지 예측, 공간 취약성 진단 및 2026 년 근미래 시나리오 분석

미세먼지($PM_{1.0}$)와 초미세먼지($PM_{2.5}$)는 단기적인 호흡기·심혈관계 악화뿐 아니라 장기적인 만성질환 및 조기 사망과도 밀접하게 연관된 대표적인 대기오염 물질이다. 국제적으로는 WHO 대기질 가이드라인 강화, 국내에서는 미세먼지 특별법 제정과 계절관리제 시행 등으로 도시 단위 대기질 관리의 중요성이 커지고 있으며, 이에 따라 단기 예측, 공간 취약성 평가, 근미래 위험 수준 점검을 결합한 실용적인 분석 체계에 대한 수요가 증가하고 있다.

본 연구는 대전광역시를 대상으로, 공공 관측자료만을 이용해 ① 1시간 뒤 $PM_{1.0}$ · $PM_{2.5}$ 농도 예측, ② 2021 - 2023년 행정동 및 동/서부 권역 단위 공간 취약성 분석, ③ 2021·2022·2023년 관측 패턴을 2026년으로 시프트한 multi-analog 시나리오 및 ensemble 취약성 평가를 하나의 end-to-end 파이프라인 안에서 통합한 로컬 케이스 스터디를 제시한다. 이를 위해 에어코리아 도시대기 측정소 PM 자료와 기상청 ASOS 기상자료, 로컬 PM 경보 이력, 국가 황사·미세먼지 특보 정보를 결합하여 1시간 간격 시계열 데이터테이블을 구축하고, 시차(lag)·이동평균 피쳐와 기상 lag 피쳐를 반영한 Random Forest 및 XGBoost 기반 1시간 뒤 예측 모형을 학습하였다.

모델은 2021 - 2022년 데이터를 학습에 사용하고 2023년(검증)과 2024년(외부 검증)에서 성능을 평가한 결과, $PM_{1.0}$ · $PM_{2.5}$ 에 대해 대체로 결정계수 R^2 약 0.8 - 0.9 수준의 예측력을 유지하였다. 반면 로컬 PM 경보 및 황사 특보 시기의 고농도 구간에서는 전반적인 오차가 증가하여, 고농도 이벤트가 현재 피쳐 구성에서 모델 성능의 주요 취약 조건임을 확인하였다.

QGIS와 Python 기반 공간 분석에서는 2021 - 2023년 시간×행정동 단위 평균 PM 및 노출 지표를 집계하고, WHO·한국 연평균 기준과 로컬 PM 경보·황사 특보 정보를 결합하여 취약성을 평가하였다. 그 결과, 관평동·문평동·노은동·둔산동·문창동·정림동 등 일부 행정동이 $PM_{1.0}$ · $PM_{2.5}$ 평균 농도와 고농도 시간 비율이 모두 높은 구조적 고위험 지역으로 나타났으며, 동부권(동·중·대덕구)이 서부권(서·유성구)에 비해 평균 농도와 고농도 시간 비율이 전반적으로 높은 경향을 보였다.

근미래 분석을 위해 2021·2022·2023년을 각각 2026년의 가능한 패턴으로 간주한 multi-analog 시나리오(Scenario A/B/C)를 구성하고, 학습된 RF/XGBoost 모델로 2026년 PM_{10} · $PM_{2.5}$ 분포를 예측하였다. 세 시나리오와 두 모델, 두 오염물질을 ensemble하여 high-episode 발생 비율과 high-risk class 출현 횟수를 평가한 결과, $PM_{2.5}$ 기준에서는 도시대기 측정소 전 지점이 ensemble 관점에서 high-risk로 분류된 반면, PM_{10} 기준 high-risk 측정소는 존재하지 않았다. 이는 대전 도시대기 측정망 전체가 $PM_{2.5}$ 측면에서 구조적으로 높은 위험 수준에 노출되어 있음을 시사한다.

본 연구는 공공 관측자료만으로 1시간 뒤 PM_{10} · $PM_{2.5}$ 예측, 현재(2021-2023 기준) 공간 취약성, 근미래(2026) multi-analog 시나리오를 하나의 재현 가능한 데이터·모델·공간 분석 파이프라인으로 연결하였다는 점에서 의의를 갖는다. 또한 행정동 및 동/서부 권역 단위에서 PM_{10} · $PM_{2.5}$ 를 동시에 고려한 취약성 분석과 ensemble 위험도 평가를 통해, 도시 대기질 관리에서의 집중 관리 구역 선정, 로컬 정보 체계 보완, 물리 기반 대기질 모델과의 연계 연구 및 기후·배출 시나리오 확장 연구에 활용 가능한 기초 틀을 제공한다.

핵심되는 말: PM_{10} , $PM_{2.5}$, 단기 예측, 공간 취약성, 시나리오 분석, 대전, 머신러닝, QGIS, Power BI, 공공데이터

1. 서론

1.1. 연구 목적 및 필요성

본 연구는 미세먼지(PM₁₀)와 초미세먼지(PM_{2.5})는 입경이 작고 호흡기에 깊숙이 침투할 수 있어, 단기적으로는 호흡기·심혈관계 질환 악화, 응급실 방문 증가, 사망률 상승과 관련되고, 장기적으로는 만성 폐질환, 심혈관 질환, 조기 사망과 같은 중대한 건강 피해를 유발하는 것으로 알려져 있다[14,15]. 이러한 건강 영향에 대한 인식이 강화됨에 따라 국제사회와 국내에서는 대기질 관리 기준을 상향 조정하고, 고농도 상황에 대한 경보 체계를 운영하는 등 다양한 정책적 노력을 기울이고 있다[14,16 - 18].

세계보건기구(WHO)는 2021년 대기질 가이드라인을 개정하여 PM₁₀·PM_{2.5}의 연평균 및 단기 기준을 기존보다 크게 강화하였다[16]. 국내에서도 미세먼지 특별법 제정, 계절관리제 시행, 배출 저감 정책 등 다양한 제도가 도입되면서, 고농도 미세먼지 저감을 위한 제도적 기반이 확대되고 있다[17,18]. 그러나 대기질 관리의 최종적인 실행 단위는 개별 도시이며, 도시에 따라 배출 특성, 지형, 기상 조건, 인구 분포가 상이하므로, 도시 단위에서의 정밀한 분석과 맞춤형 관리 전략이 요구된다.

도시 단위 대기질 관리는 크게 세 가지 축에서 접근할 수 있다. 첫째, 단기 예측을 통해 향후 몇 시간~하루 이내의 농도 변화를 예측하고, 경보 발령 및 행동 요령 안내에 활용하는 것, 둘째, 공간적 취약성을 평가하여 어떤 지역이 구조적으로 높은 농도와 노출을 경험하는지를 파악하는 것, 셋째, 근미래 시나리오나 정책 시나리오를 통해 향후 위험 수준의 변화를 점검하는 것이다. 본 연구는 이러한 세 축을 공공 관측자료만을 이용하여 하나의 파이프라인에서 연결하는 것을 목표로 한다.

1.2. 선행연구 동향

관련 연구는 크게 네 가지 방향으로 정리할 수 있다.

첫째, 단일 지점 또는 소수 지점을 대상으로 한 단기 예측 연구가 다수 수행되어 왔다. LSTM, GRU, CNN과 같은 딥러닝 모형이나 Random Forest, XGBoost 등의 트리 기반 머신러닝 모형을 활용하여 특정 측정소의 1시간 뒤 혹은 1일 뒤 PM_{10} · $PM_{2.5}$ 농도를 예측하는 연구들이 보고되었다[1 - 4]. 이들 연구는 과거 PM 농도와 기상 변수(기온, 상대습도, 풍속, 풍향, 강수량 등)를 입력 피처로 사용하며, RMSE, MAE, R^2 등 예측 성능 지표를 중심으로 모델 간 비교를 수행하는 경향이 있다. 그러나 예측 결과를 행정구역 단위 공간 취약성 분석으로 확장하거나, 경보·황사 특보와 연계하여 노출 관점에서 해석한 사례는 상대적으로 많지 않다.

둘째, 광역·국가 규모의 물리 기반 3차원 수치모델(CMAQ, WRF-Chem 등)을 활용한 연구들이 있다[5 - 7]. 이러한 모델은 기상장, 배출 인벤토리, 화학 반응 모듈 등을 결합하여 대규모 영역에서 장기 평균 농도와 정책 시나리오(예: 배출 감축)의 효과를 평가하는 데 널리 활용된다. 물리·화학 과정을 명시적으로 다루고 다양한 시나리오 모의를 수행할 수 있다는 장점이 있으나, 모델 구성과 계산 비용이 크고, 단일 도시·행정동 수준의 공공 관측자료와 직접 결합하여 실무자가 재현하기에는 진입장벽이 높다는 한계가 있다.

셋째, 정적인(static) 공간 분포 지도 작성에 초점을 맞춘 GIS 기반 연구가 수행되어 왔다[8 - 10]. 특정 연도 또는 계절의 평균 PM 농도를 행정구역별로 시각화하여, 평균 농도 수준이나 기준 초과 여부를 지도로 보여주는 연구들이 대표적이다. 그러나 많은 경우 장기 평균값에만 초점을 맞추고 있어, 시간대·계절별 변동성과 로컬 PM 경보 및 황사 특보 시기의 고농도 노출, 머신러닝 예측값의 오차 패턴 등을 통합한 공간 분석은 제한적으로 수행되었다.

넷째, 기후·배출 시나리오 기반 미래 농도 평가 연구가 있다[11 - 13]. RCP/SSP 등 기후 시나리오와 배출 시나리오를 결합하여 2030년, 2050년과 같은 미래 시점의 평균 농도 변화나 기준 초과 빈도 변화를 평가하는 연구들이다. 이러한 연구는 장기적·광역적 관점에서는 유용하지만, 도시 단위에서 공공 관측자료와 머신러닝 모델을

결합하여 단기 예측·공간 취약성·근미래 시나리오 분석을 하나의 파이프라인으로 연계한 사례는 상대적으로 부족하다.

1.3. 연구 공백

상기 선행연구 동향을 고려할 때, 본 연구가 다루는 연구 공백은 다음과 같이 정리할 수 있다.

(1) 머신러닝 기반 단기 예측 연구는 주로 단일 지점 또는 소수 지점의 예측 성능 비교에 초점을 두고 있으며, 예측값과 성능 지표를 행정동·권역 단위의 공간 취약성 분석과 체계적으로 연결한 사례는 드물다[1 - 4].

(2) 물리 기반 3D 수치모델은 광역·국가 수준 정책 평가에는 강력한 도구이지만, 단일 도시를 대상으로 공공 관측자료만을 활용해 재현 가능한 분석 체계를 구축하기에는 데이터·전산 자원 측면에서 부담이 크다. 실무자 수준에서 접근 가능한 경량화된 데이터 기반 파이프라인에 대한 수요가 여전히 존재한다.

(3) 정적 평균 지도 중심 연구는 특정 시점 또는 기간의 평균 농도와 기준 초과 여부를 직관적으로 보여주지만, 시간대·계절별 변동성, 로컬 PM 경보 및 황사 특보 시기의 고농도 노출, 머신러닝 예측 모델의 성능 차이를 함께 고려한 공간 취약성 분석은 충분히 이루어지지 않았다. 특히 PM_{10} 과 $PM_{2.5}$ 를 동시에 고려해 취약성을 정의한 연구는 제한적이다[8 - 10].

(4) 기후·배출 시나리오 기반 미래 농도 평가 연구는 장기적·광역적 관점에서는 유용하지만, “최근 몇 년의 관측 패턴이 근미래에 반복될 경우 어떤 지역이 지속적으로 취약한지”를 다루는 multi-analog 및 ensemble 접근은 상대적으로 새로운 시도이다[11 - 13]. 과거 3년(2021 - 2023)을 근미래(2026)의 가능한 패턴으로 가정하고, 이를 머신러닝 예측 모델과 결합해 취약성을 평가하는 연구는 많지 않다.

따라서 본 연구의 기여는 다음 세 가지로 요약할 수 있다.

(1) 공공 PM·기상 관측자료와 단순 시계열 피처를 이용하여 1시간 뒤 PM_{10} ·

PM_{2.5}를 예측하고, 예측값과 오차 패턴을 행정동·권역 단위 공간 취약성 분석과 직접 연결하는 통합 프레임워크를 제시한다.

(2) 행정동 및 동/서부 권역 단위에서 PM₁₀과 PM_{2.5}를 동시에 고려한 취약성 지표를 정의하고, 평균 농도·기준 초과 비율·경보·황사 시기 노출을 결합한 다차원 평가를 수행한다.

(3) 2021 - 2023년을 2026년으로 시프트한 multi-analog 시나리오와 RF/XGBoost 모델, 두 오염물질을 통합한 ensemble 분석을 통해, 근미래 다양한 패턴에서도 반복적으로 고위험으로 나타나는 공간적 취약 구역을 탐지하는 로컬 케이스 스터디를 제시한다.

1.4. 연구 목적 및 연구 질문

본 연구의 전반적인 목적은 대전광역시를 대상으로 공공 관측자료만을 활용하여,

(i) 1시간 뒤 PM₁₀·PM_{2.5} 농도 예측,

(ii) 2021 - 2023년 행정동 및 동/서부 권역 단위 공간 취약성 분석,

(iii) 2021 - 2023년 관측 패턴을 2026년으로 시프트한 multi-analog 시나리오 및 ensemble 취약성 평가를

하나의 end-to-end 파이프라인으로 구현하는 데 있다. 이를 위해 다음 세 가지 연구 질문을 설정하였다.

RQ1. 공개 PM·기상 데이터와 단순 시계열 피쳐만으로, 대전 11개 도시대기 측정소에서 1시간 뒤 PM₁₀·PM_{2.5} 농도를 연도·조건이 바뀌어도 안정적으로 예측할 수 있는가?

이를 검증하기 위해 2021 - 2022년 데이터를 학습에 사용하고, 2023년(검증)과 2024년(외부 검증)에서 PM₁₀·PM_{2.5} 각각에 대해 R², RMSE, MAE를 평가하였다. 또한 평상시(normal), 로컬 PM 경보 시간대, 국가 황사 특보 시간대, 고농도 이벤트 시간대 등 조건별로 성능을 비교하여, 모델의 취약 조건과 일반화 가능성을 정

량적으로 분석하였다.

RQ2. 2021 - 2023년 동안 대전 행정동 및 동/서부 권역에서 평균 농도, 기준 초과 비율, 로컬 PM 경보 · 황사 특보 시간대 노출은 어떻게 공간적으로 분포하는가?

이를 위해 행정동별 3년 평균 PM_{10} · $PM_2.5$, WHO/한국 연평균 기준 초과 여부, PM 경보 · 황사 특보 시간대 평균 PM과 누적 노출 시간, 동부권/서부권 단위 요약 통계를 산출하여, PM_{10} 과 $PM_2.5$ 를 동시에 고려한 구조적 취약 영역을 도출하였다.

RQ3. 2021 · 2022 · 2023년의 관측 패턴이 2026년에 다시 나타난다고 가정할 때, 세 연도를 각각 2026으로 시프트한 세 개의 아날로그 시나리오 (Scenario A/B/C)에서 PM_{10} 과 $PM_2.5$ 모두에 대해 항상 고농도이거나, 시나리오에 상관없이 취약한 행정동 · 권역이 존재하는가?

이를 위해 2021/2022/2023을 각각 2026으로 매핑한 Scenario A/B/C를 구성하고, 학습된 RF/XGBoost 모델로 PM_{10} · $PM_2.5$ 분포를 예측하였다. 각 행정동에 대해 시나리오별 평균 농도, 기준 초과 시간 비율(예: $PM_{10} \geq 50 \mu g/m^3$, $PM_2.5 \geq 25 \mu g/m^3$), 세 시나리오 · 두 모델(RF/XGBoost)을 모두 고려한 ensemble 고농도 episode 비율을 계산하여, 여러 미래 패턴에서도 반복적으로 고위험으로 나타나는 행정동 · 권역을 탐지하였다.

본 논문의 구성은 다음과 같다. 2장에서는 연구 대상 지역과 사용된 데이터셋을 정리하고, 3장에서는 데이터 처리 파이프라인, 피처 엔지니어링, Random Forest/XGBoost 모델, QGIS 기반 공간 분석, Power BI 대시보드, 2026년 multi-analog 시나리오 구성 등 방법론을 통합적으로 설명한다. 4장에서는 세 연구 질문(RQ1 - RQ3)에 대응하는 결과를 순차적으로 제시하며, 5장에서는 이들 결과를 종합적으로 해석하고 한계와 정책적 시사점을 논의한다. 마지막으로 6장에서는 연구의 주요 결론과 향후 연구 및 실무 적용 방향을 요약한다.

2. 연구 대상 지역 및 데이터

2.1. 연구 대상 지역

대전광역시는 대한민국 중부 내륙에 위치한 광역시로, 도시·주거·상업·산업 지역이 혼재된 중규모 도시이다. 본 연구에서는 대전광역시 내 도시대기 측정소 11개소를 분석 대상으로 선정하였다. 각 측정소의 위치는 에어코리아에서 제공하는 좌표 정보를 기반으로 하였으며, 행정동 경계와 함께 GIS 상에서 확인하였다(그림 1).




그림 1

행정구역은 동부권과 서부권으로 구분하였다. 동부권은 동구·중구·대덕구, 서부권은 서구·유성구에 해당하며, 이 구분은 도시 구조, 배출 특성, 주요 교통축 및 산업·주거 분포를 고려한 것이다. 동부권은 상대적으로 산업·물류·구도심 비중이 높고, 서부권은 주거·교육·연구·업무 기능이 강한 특성을 보인다. 이러한 공간적 차이를

반영하기 위해, 이후 분석에서는 행정동 단위뿐 아니라 동부권/서부권 권역 단위 지표도 함께 산출하였다.

2.2. 대기질 데이터

PM 자료는 에어코리아에서 제공하는 대전 도시대기 측정소 월별 확정 자료를 이용하였다. 원자료는 측정소별, 시각별 PM₁₀·PM_{2.5} 농도로 구성되어 있으며, 월별 엑셀 파일을 수집한 뒤 시계열 형태로 정리하여 raw_pm_final 데이터테이블을 구축하였다(표 1).

raw_pm_final의 주요 특성은 다음과 같다.

시간범위	2021-01-01 01:00 ~ 2024-12-31 23:00
시간 해상도	1시간
공간 단위	대전 도시대기 측정소 11개소
주요 변수	ts_kst(한국 표준시 기준 시각), station_id, pm10, pm25

표 1

데이터 구축 과정에서, 중복 시간 레코드는 제거하였고, 명백한 오기 또는 센서 오류로 판단되는 극단값은 품질 검토 후 제거하거나 결측 처리하였다. 짧은 구간의 결측은 제한적인 보간을 통해 보완하였으며, 장기 결측 구간은 분석에서 제외하였다.

2.3. 기상 데이터

기상 자료는 기상청 ASOS(종관기상관측) 지점 자료를 활용하였다. 대전 인근 ASOS 지점에서 관측된 기온, 상대습도, 풍속, 풍향, 강수량 등의 자료를 수집하여, raw_weather_final 데이터테이블을 구축하였다(표 2).

raw_weather_final의 주요 특성은 다음과 같다.

시간 범위 및 해상도	2021-01-01 01:00 ~ 2024-12-31 23:00, 1시간 간격
주요 변수	ts_kst, temperature, relative_humidity, wind_speed, wind_dir, precipitation 등

표 2

모든 기상자료는 ts_kst를 기준으로 PM 자료와 동일한 시간축에 맞추어 정렬하였다. 이후 PM 예측 모델은 이러한 기상 변수와 PM 시계열을 함께 입력 피처로 사용하여 농도 변동을 설명하도록 설계하였다.

2.4. 지역 PM 정보 및 황사 정보

지역 PM 정보 및 황사·미세먼지 특보 자료는 환경부·기상청 공개 자료를 기반으로 정리하였다.

로컬 PM 정보는 PM_{10} · $PM_{2.5}$ 농도가 일정 기준을 초과할 때 발령된 경보·주의보 이력을 바탕으로, local_alert_events_pm10 및 local_alert_events_pm25 데이터테이블을 구축하였다. 각 테이블은 ts_kst, area(동부/서부), y_loc_pm10 또는 y_loc_pm25(경보 단계 또는 이진 라벨) 등의 변수를 포함한다. 로컬 경보 데이터는 2021 - 2023년 구간에 대해 신뢰성 있게 수집되었다.

황사·미세먼지 특보는 dust_stage(황사 단계)를 포함하는 national_alert_events_daejeon 데이터테이블로 정리하였다. 이 테이블은 특정 시각 이 황사 특보·주의보·경보 구간에 해당하는지를 나타내며, 이후 processed_with_dust에서 dust_stage 라벨로 활용되었다.

2.5. 파생 데이터 테이블

위의 원자료를 바탕으로, 분석 목적에 맞는 파생 데이터테이블을 구성하였다(표 3).

pm_with_alerts	raw_pm_final에 local_alert_events_pm10/pm25와 national_alert_events_daejeon을 병합하여, 각 시각·측정소에 대해 y_loc_pm10, y_loc_pm25, dust_stage 라벨을 포함하도록 구성한 테이블이다.
processed_final	pm_with_alerts와 raw_weather_final을 ts_kst 기준으로 결합하고, 결측·이상치 처리를 거친 뒤, 기본적인 시간 피처(year, month, dayofweek, hour, is_weekend 등)를 추가한 테이블이다. 이 테이블은 이후 피처 엔지니어링과 모델 학습의 기반이 되었다.
processed_with_dust	processed_final에 황사·경보 관련 라벨(dust_stage, y_loc_pm10, y_loc_pm25)을 명시적으로 포함하여, 경보·황사 상황 분석 및 시나리오 구성에 활용한 테이블이다.
predictions_full_rf_xgb	Random Forest 및 XGBoost 모델을 이용해 2021 - 2024년 전체 기간에 대해 PM _{1.0} ·PM _{2.5} 1시간 뒤 농도를 예측한 결과와 잔차(residual)를 저장한 테이블이다.
processed_with_predictions_both	processed_with_dust와 predictions_full_rf_xgb를 station_id 및 ts_kst 기준으로 병합하여, 실측값, 타깃값, 예측값, 오차, 경보·황사 라벨이 모두 포함된 최종 분석용 마스터 테이블이다. 이 테이블은 Power BI 대시보드와 2026 시나리오 집계에 활용되었다.

표 3

모든 파생 데이터테이블의 시간 범위는 2021-01-01 01:00 ~ 2024-12-31 23:00로 통일하였다.

3. 연구

3.1. Overall workflow

전체 분석을 위한 데이터 파이프라인은 다음과 같은 순서로 진행되었다.

```
raw_pm_final, raw_weather_final
→ pm_with_alerts (경보 · 황사 라벨 병합)
→ processed_final (기본 전처리 및 시간 피쳐 생성)
→ processed_with_dust (경보 · 황사 라벨 통합)
→ 피쳐 엔지니어링 (lag · rolling · 기상 lag 등)
→ RF/XGBoost 모델 학습 및 예측
→ predictions_full_rf_xgb (2021 - 2024 전체 예측)
→ processed_with_preds_both (실측 · 예측 · 라벨 통합)
```

이후 processed_with_preds_both와 공간 자료(stations, daejeon_umd, daejeon_ew)를 결합하여 QGIS 분석용 레이어를 생성하고, Python으로 요약 테이블을 만들어 Power BI 대시보드를 구축하였다. 마지막으로, 2021 - 2023→2026 multi-analog 시나리오를 구성하고, RF/XGBoost 모델을 재사용하여 2026년 예측 및 ensemble 취약성 분석을 수행하였다.

3.2. Data processing

모든 시계열 데이터는 ts_kst(한국 표준시 기준 시각)를 기준으로 정렬하였다. raw_pm_final과 raw_weather_final은 ts_kst 및 station_id(또는 ASOS 지점 ID)를 기준으로 내부 조인을 수행하였으며, 이 과정에서 PM 및 기상자료 간 시간 불일치가 발생한 경우 가장 가까운 시각(± 1 시간 이내)에 대해서만 병합을 허용하였다.

로컬 경보 및 황사 특보 데이터는 ts_kst를 기준으로 processed_final에 병합하여 y_loc_pm10, y_loc_pm25, dust_stage 라벨을 생성하였다. 라벨 데이터가 존재하지 않는 시각은 “경보 없음” 또는 “황사 없음”으로 처리하였다.

결측치 처리에서는, PM 농도의 짧은 결측 구간에 대해서는 인접한 시간값의 선형 보간을 제한적으로 적용하였고, 장기 결측 또는 경계 조건(예: 다수 변수 동시 결측)에서는 해당 시점을 분석에서 제외하였다. 기상 변수의 결측은 인접 시점 보간 또는 최근 유효값 유지 (Last Observation Carried Forward)를 사용하였다.

3.3. Feature engineering

processed_with_dust를 기반으로, PM₁₀ · PM_{2.5} 각각에 대해 1시간 뒤 농도 (target_pm10, target_pm25)를 타깃 변수로 설정하였다. 이를 위해 pm10, pm25 시계열을 ts_kst 기준으로 1시간 미래로 시프트하여 타깃 컬럼을 생성하였다.

입력 피쳐는 다음과 같이 구성하였다.(표 4)

시간 피쳐	year, month, dayofweek, hour, is_weekend 등
PM 시계열 피쳐	pm10_lag1~3, pm10_roll_mean_3h/6h/12h/24h, pm25_lag1~3, pm25_roll_mean_3h/6h/12h 등
기상 lag 피쳐	temperature_lag1, relative_humidity_lag1, wind_speed_lag1
경보	y_loc_pm10, y_loc_pm25, dust_stage(필요 시 더미 변수화)

표 4

lag 및 rolling 피쳐 생성 과정에서, 초기 몇 시간에 해당하는 불완전 시계열 구간은 분석에서 제외하였다. 타깃과 피쳐 간 시점 정렬을 유지하기 위해, 모든 피쳐는 타깃 생성 이후 동일한 인덱스를 기준으로 정리하였다.

3.4. Machine learning models

단기 예측을 위해 트리 기반 앙상블 모델인 Random Forest와 Gradient Boosting 계열 모델인 XGBoost를 사용하였다. 두 모델 모두 비선형 관계와 변수 간 상호작용을 유연하게 표현할 수 있으며, 비교적 해석이 용이하다는 장점이 있다.

데이터 분할은 다음과 같이 수행하였다(표 5).

Train	2021 - 2022년 전체 자료
Validation	2023년 전체 자료
External test	2024년 전체 자료

표 5

PM₁₀ · PM_{2.5} 각각에 대해 별도의 모델을 학습하였다. Random Forest에서는 n_estimators, max_depth, min_samples_leaf 등의 하이퍼파라미터를, XGBoost에서는 learning_rate, max_depth, subsample, colsample_bytree 등을 탐색하여 적절한 값을 선정하였다. 하이퍼파라미터 최적화는 검증 연도(2023년)에서의 RMSE 및 R²를 기준으로 수행하였으며, 세부 설정값은 부록에 제시하였다.

학습 완료 후, Train(2021 - 2022)에 대해 모델을 피팅하고 Validation(2023) 및 External test(2024) 전체 기간에 대해 예측을 수행하였다. 또한 모델 일반화 성능 평가를 위해, 학습 · 검증 · 외부 검증 연도 전체(2021 - 2024)에 대해 예측값을 생성하여 predictions_full_rf_xgb에 저장하였다.

3.5. Spatial analysis with QGIS

공간 분석은 QGIS와 GeoPandas를 이용해 수행하였다. 먼저 stations.csv에 포함된 측정소 좌표(dmX, dmY, WGS84 기준)를 기반으로 측정소 포인트 레이어를 생성하고, 이를 EPSG:4326에서 EPSG:5186으로 변환하였다. 이어서 대전 행정동 경계(daejeon_umd)를 불러와 동일 좌표계(EPSG:5186)로 변환한 뒤, 공간 조인(spatial join)을 통해 각 측정소를 해당 행정동에 매핑하였다(그림 2).




그림 2

processed_with_preds_both에서 2021 - 2023년 구간을 추출하고, station_id와 ts_kst별 PM_{10} · $PM_{2.5}$ 값 및 예측값을 for_qgis_2021_2023 형태의 중간 테이블로 정리한 뒤, 측정소 위치와 결합하여 stations_time_2021_2023.gpkg를 생성하였다. 이 레이어는 측정소 단위 시계열 애니메이션 구성에 사용되었다.

또한 행정동 단위 평균을 계산하기 위해, for_qgis_2021_2023과 행정동 경계를 공간조인하여 ts_kst×행정동 단위로 PM_{10} · $PM_{2.5}$ 평균을 집계한 umd_time_pm_2021_2023.gpkg를 생성하였다. 이후 3년 평균 PM 지도 및 WHO·한국 기준 초과 여부를 표현하기 위해, 행정동별 평균 및 기준 초과 비율을 요약한 umd_pm_stats_2021_2023_pm10.gpkg, umd_pm_stats_2021_2023_pm25.gpkg를 작성하였다. 동부권/서부권 권역 정보는 daejeon_ew.gpkg를 통해 추가하였다.

3.6. Summary statistics & Power BI dashboards

Python으로 작성한 요약 스크립트를 통해, 행정동·권역·조건별 통계를 담은 여러 테이블을 생성하였다(표 6). 주요 테이블은 다음과 같다.

bi_admin_pm_stats_2021_2023	행정동별 평균 PM_{10} · $PM_{2.5}$, WHO·한국 기준 초과 비율, 고농도 시간 비율
bi_area_ew_stats_2021_2023	동부권/서부권 단위 평균 농도 및 기준 초과 비율
bi_model_perf_2021_2024	연도·시즌·시간대·조건별(RF/XGBoost, PM_{10} / $PM_{2.5}$) 예측 성능(RMSE, MAE, R^2)
bi_alert_pm10_alert, bi_alert_pm25_alert, bi_alert_dust	로컬 PM 정보 및 황사 특보 시기의 노출 시간·평균 농도·최대 농도 요약

표 6

이들 테이블을 Power BI에 가져와 다음과 같은 페이지 구조를 갖는 대시보드를 구축하였다(표 7)

Overview	연도별 · 계절별 PM 수준 및 모델 성능 요약
Spatial	행정동 및 동부권/서부권 단위 취약성 지표 시각화
Alerts & Dust	로컬 PM 정보 및 황사 특보 시기 노출 패턴
Model performance	모델별 · 오염물질별 성능 비교
Scenario	2021년도, 2022년도, 2023년도를 환경데이터를 베이스로 2026년도 A, B, C 예측 시나리오 생성

표 7

대시보드는 표와 그래프 형태로 구성되어, 4장 결과 서술에서 주요 수치 및 공간 패턴을 인용하는 근거로 활용되었다.

3.7. Multi-analog scenario 2026 & ensemble risk

근미래(2026년) 취약성 분석을 위해, 2021 · 2022 · 2023년을 각각 하나의 analogue year로 간주하였다. 먼저 2021, 2022, 2023년 processed_final 기반 피쳐셋을 2026년으로 시프트한 scenario_2026_features_pm10_A/B/C, scenario_2026_features_pm25_A/B/C를 생성하였다. 각 시나리오 파일에는 PM · 기상 · 시간 피쳐가 2026년의 동일한 달 · 요일 · 시간 구조를 갖도록 매핑되어 있다.

이후 학습 완료된 RF/XGBoost 모델을 재사용하여, 각 시나리오에서 PM_{10} · $PM_{2.5}$ 1시간 뒤 농도를 예측하였다. 예측 결과는 scenario_2026_preds_pm10_rf_xgb, scenario_2026_preds_pm25_rf_xgb 테이블에 저장하였다.

행정동 및 동/서부 단위 시나리오 집계를 위해, 각 시나리오의 예측값을 stations 및 daejeon_umd와 결합하여 행정동별 평균 농도와 기준 초과 시간 비율(예: $PM_{10} \geq 50 \mu g/m^3$, $PM_{2.5} \geq 25 \mu g/m^3$)을 계산하였다. 이 과정에서 시나리오 · 모델 · 오염물질별 지표를 모은 bi_admin_pm_stats_2026_pm10, bi_admin_pm_stats_2026_pm25, bi_area_ew_stats_2026_pm10, bi_area_ew_stats_2026_pm25를 생성하였다.

마지막으로, 세 시나리오와 두 모델, 두 오염물질을 ensemble하여, 각 행정동 · 측정소가 여러 조합에서 high-risk class를 얼마나 자주 보이는지를 계산하였다. 이 정보를 바탕으로 umd_pm_stats_2026_scenarios_with_classes.gpkg 및 umd_ensemble_2026_with_classes.gpkg를 생성하고, QGIS에서 2026 시나리오별

및 ensemble 위험도 지도를 제작하였다(그림 3, 그림 4). PM10의 경우 모든 측정소가 ‘위험도 낮음’ 클래스로 분류된 반면, PM2.5의 경우 한 곳을 제외한 모든 측정소가 ‘위험도 매우 높음’ 으로 분류되었다.




그림 3 (PM10_2026_ensemble_risk)




그림 4 (PM2.5_2026_ensemble_risk)

4. 결과

4.1. RQ1 - 1hour-ahead prediction performance

본 연구의 예측 성능 평가는 Power BI 대시보드의 ‘Model performance’ (PM₁, PM_{2.5}) 페이지를 통해 수행하였다 (그림 5, 그림 6). 두 모델의 연도별 성능 지표는 2021 - 2024 년 전체 데이터 기반으로 산출되었다.

Random Forest(RF) 모델은 PM₁ 의 예측에서 검증 및 외부 검증 연도(2023 - 2024)에 RMSE 약 10.4 · 8.4 $\mu\text{g}/\text{m}^3$, MAE 약 5.6 · 4.7 $\mu\text{g}/\text{m}^3$, R^2 약 0.90 · 0.86을 기록했다. XGBoost(XGB) 모델은 동기간 RMSE 약 11.6 · 8.6 $\mu\text{g}/\text{m}^3$, R^2 0.87 · 0.85로 RF 보다 소폭 높은 오차를 보였다. PM_{2.5}의 경우 RF 모델 RMSE가 2023 · 2024년에 각각 5.4 · 4.7 $\mu\text{g}/\text{m}^3$, MAE는 3.4 · 3.2 $\mu\text{g}/\text{m}^3$, R^2 는 0.87 · 0.82였다. XGB 역시 비슷한 수준의 예측력을 보였으나, 전체적으로 RF가 조금 더 안정적인 패턴을 유지했다.

두 모델 모두 학습 기간(2021 - 2022)에는 $R^2 \approx 0.98 - 0.99$ 로 매우 높은 적합도를 보였지만, 2023 - 2024 년으로 갈수록 RMSE · MAE가 상승했다. 이 패턴은 그림 5에서 연도별 RMSE · MAE 곡선이 동시에 상승하는 형태로 확인된다. 즉, 기상 · 배출 조건의 연도별 비선형성 및 고농도 사건의 불규칙성이 모델의 일반화 성능을 제한한 것으로 해석된다.

또한 같은 그림에서 dust 및 loc_alert 조건이 포함된 샘플의 오차 분산이 확대되어 있는데, 이는 고농도 또는 특보 상황에서 모델이 피크 농도를 부분적으로 과소 추정함을 의미한다. 따라서 추가 연구에서는 이벤트 구간의 가중 학습이나 국지적 풍향 · 습도 피쳐 보강이 필요하다.




그림 5 (pm10)




그림 6 (pm2.5)

4.2. RQ2 - Spatial vulnerability in 2021 - 2023

Power BI의 ‘Overview’ (그림 7)와 ‘Spatial patterns - by neighbourhood/season’ (그림 8) 페이지를 이용해 3년간의 공간적 취약성을 분석하였다.

동부권(동·중·대덕구) 평균 PM_{10} 은 약 $34 - 37 \mu g/m^3$, 서부권(서·유성구)은 $31 - 35 \mu g/m^3$ 로 동부권이 전반적으로 높았다. $PM_{2.5}$ 평균은 동부 $17.3 \mu g/m^3$, 서부 $17.0 \mu g/m^3$ 수준이지만, 기준 초과 시간 비율은 각각 44 %, 42 %로 동부권의 노출 빈도가 조금 더 컸다.

행정동 단위 평균값을 살펴보면 (그림 7), 관평동·문평동·노은동·둔산동·문창동·정림동 등이 상대적으로 높은 PM 수준을 유지하였다. 이 동들은 교통량이 많고 상업지 비율이 높은 구간과 대체로 겹친다. 계절별 패턴 역시 그림 7에서 확인되며, 여름철 PM_{10} 은 $21 \mu g/m^3$, 겨울철 은 약 $35 - 40 \mu g/m^3$ 까지 상승해 난방 및 대기정체 요인의 영향을 보였다.

한편 ‘Alerts & Dust’ 페이지(그림 8)에서 로컬 경보와 황사 특보 시간대를 비교한 결과, 경보 시기에도 동일한 행정동들이 지속적으로 높은 PM 농도와 노출 시간을 보였다. 평상시 고농도 지역이 사건 시에도 더 취약하게 나타나는 일관된 패턴이 형성된 것이다. 이 결과는 단순 평균값 분석보다 ‘노출 지속시간’ 을 고려한 공간 위험도 평가가 도시 관리 차원에서 유의미함을 보여준다.





그림 7 (overview)



Spatial patterns – by neighbourhood, season

그림 8 (Spatial_all)



Alert & dust events – exposure patterns

그림 9 (Alerts & Dust)

4.3. 2026 multi-analog scenarios & ensemble risk

근미래 시나리오 분석은 Power BI ‘Scenario 2026 - PM₁₀/PM_{2.5}’ 및 ‘Ensemble (Part 2)’ 페이지 자료를 활용하였다 (그림 10 - 12). 시나리오 A - C(2021 - 2023 조건 전이 모형) 모두 RF와 XGBoost 두 모델의 결과가 서로 근접하며 전반적 공간 패턴 일관성이 확인되었다.

PM₁₀의 경우 2026 년 평균 농도는 동부권 37 $\mu\text{g}/\text{m}^3$, 서부권 35 $\mu\text{g}/\text{m}^3$ 수준으로 차이가 작았다. 50 $\mu\text{g}/\text{m}^3$ 초과 시간 비율은 대체로 10 % 내외이며, 상대적으로 문평동·읍내동·성남동이 높은 빈도를 보였다. (그림 10) PM_{2.5}는 평균 18 $\mu\text{g}/\text{m}^3$ 전후로 동·서부권이 유사했으나, 문평동·관평동·구성동·둔산동·정림동 등에서 $\geq 25 \mu\text{g}/\text{m}^3$ 초과 비율이 20 - 30 % 수준으로 집중되었다 (그림 11).

세 시나리오와 두 모델을 통합한 ensemble 결과(그림 12)에 따르면 11개 도시대기 측정소 모두가 PM_{2.5} 기준으로 high-risk 그룹에 해당했으며, PM₁₀에서는 해당 측정소가 없었다. 즉 PM_{2.5} 오염은 모든 측정소에 걸쳐 구조적으로 높은 위험 수준을 유지한다는 의미다. 특히 구성동과 관평동은 모든 시나리오에서 high-episode 비율 66 - 100 %를 보여 대전 도심 내에서도 지속적 취약 핫스팟으로 규정된다.

이러한 ensemble 지도 패턴은 2021 - 2023 현재 공간분포와 일관되게 동부권 내 일부 행정동이 미래에도 높은 노출 수준을 유지함을 보여준다. 따라서 이 지역들은 중장기 대기질 정책에서 우선적 관리 대상으로 설정될 필요가 있다.




그림 10 (scenario 2026 - PM10)




그림 11 (scenario 2026 – PM2.5)




그림 12 (scenario 2026 – Ensemble)

5. 논의

5.1. Predictive capability and limitations

단기 예측 관점에서, 공공 관측자료와 단순 시계열 피쳐만으로도 2023 - 2024년 검증·외부 검증 연도에서 $PM_{1.0}$ · $PM_{2.5}$ 에 대해 R^2 약 0.8 - 0.9 수준의 예측력을 확보했다는 점은, 도시 대기질 관리 실무에서 경량화된 데이터 기반 예측 도구로 활용될 수 있음을 시사한다. 지도 학습이 과거 2년(2021 - 2022)에만 기반함에도 불구하고, 이후 2년(2023 - 2024)에 대해 비교적 높은 설명력을 유지했다는 점에서, 본 연구의 피쳐 구성과 모델 선택이 기본적인 시간·기상 패턴을 잘 포착하고 있음을 확인할 수 있다.

반면 로컬 PM 경보·황사 특보 및 고농도 이벤트 시기의 오차 증가는 현재 파이프라인의 한계를 드러낸다. 고농도 상황에서는 상층 기류, 국지적 배출 급증, 2차 생성 등 다양한 요인이 복합적으로 작용하므로, 단순 시계열·기상 피쳐만으로는 이러한 비선형성을 충분히 설명하기 어렵다. 이는 교통량, 산업 배출량, 국지 배출 지표, 장거리 이동지수 등 추가 피쳐 도입 또는 물리 기반 모델과의 하이브리드 접근이 필요함을 의미한다.

5.2. Spatial vulnerability and policy implications

공간 취약성 분석 결과는, 현재(2021 - 2023)와 근미래(2026) 모두에서 반복적으로 높은 노출을 보이는 행정동·권역이 존재한다는 점을 보여준다. 특히 관평동·문평동·노은동·둔산동·문창동·정림동 등은 $PM_{1.0}$ · $PM_{2.5}$ 평균 농도와 고농도 시간 비율이 모두 높고, 2026 multi-analog 시나리오에서도 $PM_{2.5}$ 기준 high-risk로 반복적으로 분류되었다. 이러한 지역은 장기적인 관리 대상 구역으로 우선순위를 부여할 필요가 있다.

동부권/서부권 비교 결과를 보면, 동부권이 서부권에 비해 평균 농도와 기준 초과 비율이 전반적으로 높은 경향을 보인다. 이는 구도심, 산업·물류, 교통축이 집중된 동부권 특성과 연관이 있을 가능성이 크며, 향후 정책 설계 시 동부권 내 특정 행정동을 대상으로 한 맞춤형 저감 대책(교통 수요 관리, 저배출 차량 확대, 국지적 배출 저감 등)을 검토할 필요가 있다.

또한 $PM_{1.0}$ 과 $PM_{2.5}$ 의 차이에서 나타나는 정책적 함의도 중요하다. ensemble 분석에서 $PM_{2.5}$ 기준 high-risk 측정소는 전 측정소에 해당하는 반면, $PM_{1.0}$ 기준 high

-risk 측정소는 없었다는 결과는, 같은 도시라도 입경이 작은 PM_{2.5} 관점에서 훨씬 더 넓은 지역이 구조적 위험에 노출되어 있음을 의미한다. 이는 규제 및 관리 기준, 정보 체계 설계, 건강 영향 평가에서 PM_{2.5}에 보다 엄격한 관심을 기울일 필요가 있음을 시사한다.

5.3. Strengths, limitations and future work

본 연구의 장점은, 에어코리아·기상청·로컬 경보·황사 특보 등 공공 데이터만을 활용하여 누구나 재현 가능한 데이터·모델·공간 분석 파이프라인을 제시했다는 점이다. 모든 처리 단계와 파생 데이터테이블 구조를 명시함으로써, 다른 도시나 기간에도 유사한 틀을 적용할 수 있는 확장성을 확보하였다. 또한 단기 예측, 공간 취약성, 근미래 시나리오를 하나의 end-to-end 프레임워크로 통합함으로써, “현재도 높고 미래에도 높을 가능성이 큰” 공간적 취약 구역을 체계적으로 식별하는 방법론을 제시하였다.

한편, 본 연구는 몇 가지 한계를 가진다. 첫째, 분석 기간이 2021 - 2024년으로 제한되어 있어, 기후 요인 또는 장기 배출 추세를 충분히 포착하기에는 기간이 짧다. 둘째, 기상자료는 단일 ASOS 지점 또는 소수 지점 자료에 의존하고 있어, 국지적인 기상 변동성을 충분히 반영하지 못할 가능성이 있다. 셋째, 로컬 경보 및 황사 특보 정의는 행정기관의 기준에 따라 이산적인 단계로 제공되므로, 경계부근 상황에서의 연속적 노출 강도를 완전히 표현하기 어렵다. 넷째, 추가적인 배출·교통·인구 노출 관련 피처를 포함하지 않았기 때문에, 고농도 이벤트의 원인분석 및 건강 영향 평가까지 확장하기에는 정보가 부족하다.

향후 연구에서는 분석 기간을 확대하고, 다수 기상 지점 또는 재분석 자료를 활용하여 기상장의 공간 변동성을 보다 정밀하게 반영할 필요가 있다. 또한 교통량, 산업 활동, 인구 분포 등 추가 피처를 도입하여 고농도 이벤트의 원인 분석과 취약 인구 노출 평가를 병행하는 것이 바람직하다. 물리 기반 대기질 모델(CMAQ, WRF-Chem 등)과의 연계 또는 하이브리드 모델링을 통해, 현재의 데이터 기반 파이프라인을 보완하는 방향도 유망하다. 마지막으로, 다른 도시 또는 권역에 본 연구 프레임워크를 적용해 비교 분석을 수행함으로써, 한국 도시 대기질 취약성의 공간적 패턴을 보다 넓은 스케일에서 이해하는 것도 중요한 과제가 될 것이다.

6. 결론

본 연구는 대전광역시를 대상으로 공공 관측자료만을 활용하여, 1시간 뒤 $PM_{1.0}$ · $PM_{2.5}$ 예측, 2021 - 2023년 공간 취약성 분석, 2026년 multi-analog 시나리오 및 ensemble 취약성 평가를 하나의 end-to-end 파이프라인으로 통합한 로컬 케이스 스터디를 수행하였다.

첫째, 공개 PM · 기상 데이터와 단순 시계열 피쳐만으로도, 대전 11개 도시대기 측정소에서 1시간 뒤 $PM_{1.0}$ · $PM_{2.5}$ 농도를 2023 - 2024년 검증 · 외부 검증 연도 기준 R^2 약 0.8 - 0.9 수준으로 예측할 수 있음을 확인하였다(RQ1). 이는 공공 데이터와 비교적 단순한 피쳐 조합만으로도 실무에서 활용 가능한 수준의 단기 예측력을 확보할 수 있음을 보여준다. 동시에, 로컬 PM 정보 · 황사 특보 및 고농도 이벤트 시기의 오차 증가는 고농도 상황에서의 추가 피쳐 및 모형 개선 필요성을 시사한다.

둘째, 2021 - 2023년 행정동 및 동/서부 권역 단위 공간 취약성 분석을 통해, 동부권이 서부권보다 평균 농도와 기준 초과 비율이 전반적으로 높고, 관평동 · 문평동 · 노은동 · 둔산동 · 문창동 · 정림동 등 일부 행정동이 $PM_{1.0}$ · $PM_{2.5}$ 모두에서 구조적인 고위험 패턴을 보인다는 점을 확인하였다(RQ2). 이는 도시 내에서도 배출 · 지형 · 기상 · 도시 구조의 차이에 따라 취약성이 공간적으로 뚜렷이 구분된다는 점을 시사한다.

셋째, 2021 · 2022 · 2023년 관측 패턴을 2026년으로 시프트한 multi-analog 시나리오와 RF/XGBoost 모델, $PM_{1.0}$ · $PM_{2.5}$ 를 통합한 ensemble 분석을 통해, 다양한 근미래 패턴에서도 반복적으로 high-risk로 나타나는 행정동 · 권역이 존재함을 보였다(RQ3). 특히 $PM_{2.5}$ 기준에서 전 측정소가 ensemble high-risk로 나타난 반면, $PM_{1.0}$ 기준 high-risk 측정소는 없었다는 점은, 도시 대기질 관리에서 $PM_{2.5}$ 에 대한 우선적인 관리 필요성을 강조한다.

종합하면, 본 연구는 공공 관측자료만으로 단기 예측 · 공간 취약성 · 근미래 시나리오를 통합한 재현 가능한 분석 프레임워크를 제시하고, $PM_{1.0}$ 과 $PM_{2.5}$ 를 동시에 고려한 취약성 분석 및 ensemble 위험도 평가를 통해, 향후 도시 대기질 관리와 심화 모형 연구에 활용 가능한 기초 자료를 제공하였다. 향후에는 데이터 기간 확대, 추가 피쳐 도입, 타 도시 적용, 물리 기반 모델과의 연계 및 장기 기후 · 배출 시나리오 통합 등을 통해 본 연구의 틀을 보다 일반화 · 고도화하는 것이 필요하다.

참고 문헌

- [1] Ho, C.-H., Park, I., Kim, J., & Lee, J.-B. (2023). PM2.5 Forecast in Korea using the Long Short-Term Memory (LSTM) Model. *Asia-Pacific Journal of Atmospheric Sciences*, 59(5), 563 - 576. <https://doi.org/10.1007/s13143-022-00293-2>
- [2] Joharestani, M. Z., Cao, C., Ni, X., Bashir, B., & Talebiesfandarani, S. (2019). PM2.5 Prediction Based on Random Forest, XGBoost, and Deep Learning Using Multisource Remote Sensing Data. *Atmosphere*, 10(7), 373. <https://doi.org/10.3390/atmos10070373>
- [3] Ma, J., Cheng, J., Li, W., & Zhang, H. (2020). Application of the XGBoost Machine Learning Method in PM2.5 Prediction: A Case Study of Shanghai. *Aerosol and Air Quality Research*, 20(1), 128 - 138. <https://doi.org/10.4209/aaqr.2019.11.0594>
- [4] Yang, G., Yu, Y., Zhang, W., & Chen, Y. (2020). A Hybrid Deep Learning Model to Forecast Particulate Matter Concentration Levels in Beijing. *Atmosphere*, 11(4), 348. <https://doi.org/10.3390/atmos11040348>
- [5] Byun, D., & Schere, K. L. (2006). Review of the Governing Equations, Computational Algorithms, and Other Components of the Models-3 Community Multiscale Air Quality (CMAQ) Modeling System. *Applied Mechanics Reviews*, 59(2), 51 - 77. <https://doi.org/10.1115/1.2128636>
- [6] Appel, K. W., Bash, J. O., Fahey, K. M., Foley, K. M., Gilliam, R. C., Hogrefe, C., ... & Pouliot, G. (2021). The Community Multiscale Air Quality (CMAQ) Model Version 5.3.1: Features and Updates. *Geoscientific Model Development*, 14(5), 2867 - 2897. <https://doi.org/10.5194/gmd-14-2867-2021>
- [7] Choi, M.-Y., Park, R. J., Jeong, J. I., & Kim, S.-W. (2019). Comparison of PM2.5 Chemical Components over East Asia Simulated by WRF-Chem and WRF/CMAQ. *Atmosphere*, 10(10), 618. <https://doi.org/10.3390/atmos10100618>

- [8] Jeong, J.-C. (2018). The Variation Analysis on Spatial Distribution of PM10 and PM2.5 in Seoul. *Journal of Environmental Impact Assessment*, 27(6), 717 - 726. <https://doi.org/10.14249/eia.2018.27.6.717>
- [9] Nam, H., Lee, S., & Kim, H. (2025). Typhoon-Induced High PM10 Concentration Events in South Korea. *Atmosphere*, 16(4), 473. <https://doi.org/10.3390/atmos16040473>
- [10] Bozdağ, A., Yavuz, E., & Baloch, M. A. (2020). Spatial Prediction of PM10 Concentration Using Machine Learning and GIS: A Case Study of Istanbul, Turkey. *Environmental Research*, 184, 109318. <https://doi.org/10.1016/j.envres.2020.109318>
- [11] Silva, R. A., West, J. J., Lamarque, J.-F., Shindell, D. T., Collins, W. J., Faluvegi, G., ... & Zikova, N. (2017). Future Global Mortality from Changes in Air Pollution Attributable to Climate Change. *Nature Climate Change*, 7(9), 647 - 651. <https://doi.org/10.1038/nclimate3354>
- [12] Zhang, Y., Wang, K., Wang, L., Li, J., Jiang, J., & Zhu, L. (2016). Implications of RCP Emissions on Future PM2.5 Air Quality and Direct Radiative Forcing over China. *Journal of Geophysical Research: Atmospheres*, 121(21), 12985 - 13008. <https://doi.org/10.1002/2016JD024845>
- [13] Jeong, J., Park, R. J., Yeh, S.-W., Lee, S., Park, M., & Kim, S.-W. (2025). Future Projections of Winter Haze Events in Northern East Asia under Different Shared Socioeconomic Pathways. *Science of the Total Environment*, 1004, 180805. <https://doi.org/10.1016/j.scitotenv.2024.180805>
- [14] Bae, S., & Hong, Y.-C. (2018). Health Effects of Particulate Matter. *Journal of the Korean Medical Association*, 61(12), 749 - 755. <https://doi.org/10.5124/jkma.2018.61.12.749>
- [15] Oh, J.-A., Kim, S.-Y., Lee, J.-T., Choi, H., & Yi, S.-M. (2024). Mortality Burden Due to Short-Term Exposure to Fine Particulate Matter in Korea. *Journal of Preventive Medicine and Public Health*, 57(2), 185 - 196. <https://doi.org/10.3961/jpmph.23.351>

[16] World Health Organization. (2021). WHO Global Air Quality Guidelines: Particulate Matter (PM_{2.5} and PM₁₀), Ozone, Nitrogen Dioxide, Sulfur Dioxide and Carbon Monoxide. Geneva: World Health Organization.

[17] National Assembly of the Republic of Korea. (2018). Special Act on the Reduction and Management of Fine Dust (Act No. 16272).

[18] Korea Ministry of Environment. (2020). Comprehensive Plan on Fine Dust Management (2020 - 2024). Sejong: Ministry of Environment.

ABSTRACT

One-hour-ahead PM10/PM2.5 prediction, spatial vulnerability assessment, and 2026 near-future scenario analysis using public air-quality data in Daejeon, Korea

Fine particulate matter (PM10 and PM2.5) is a representative air pollutant that is closely associated not only with short-term aggravation of respiratory and cardiovascular diseases but also with long-term chronic morbidity and premature mortality. With the strengthening of the WHO Air Quality Guidelines and the implementation of the Special Act on the Reduction and Management of Fine Dust and seasonal management policies in Korea, the importance of city-scale air-quality management has increased. Accordingly, there is growing demand for practical analytical frameworks that integrate short-term forecasting, spatial vulnerability assessment, and screening of near-future risk levels.

This study presents a local case study for Daejeon, Korea, which integrates, within a single end-to-end pipeline relying solely on public monitoring data, (i) one-hour-ahead prediction of PM10 and PM2.5 concentrations, (ii) spatial vulnerability assessment at the administrative-dong and East/West sector levels for 2021–2023, and (iii) a multi-analog scenario and ensemble vulnerability analysis that maps the observed patterns in 2021, 2022, and 2023 onto 2026. To this end, we construct an hourly time-series data table by combining PM measurements from the AirKorea urban air-monitoring network with ASOS meteorological data from the Korea Meteorological Administration, local PM alert records, and national dust/fine-dust advisories. Random Forest and XGBoost models for one-hour-ahead prediction are trained using lagged and moving-average features of PM and meteorological variables.

Using 2021–2022 data for model training and 2023 (validation) and 2024 (external test) for evaluation, the models generally achieve coefficients of determination (R^2) of approximately 0.8–0.9 for both PM10 and PM2.5. In contrast, error magnitudes increase during high-concentration periods associated with local PM alerts and national dust advisories, indicating that such high-pollution episodes constitute a key vulnerability of the current feature set and modeling approach.

For spatial analysis, QGIS and Python are used to aggregate hourly PM concentrations and exposure indicators at the administrative-dong level for 2021–2023, and to evaluate vulnerability by combining WHO and Korean annual standards with local PM alert and dust-advisory information. The results show that several administrative dong, including Gwanpyeong-dong, Munpyeong-dong, Noeun-dong, Dunsan-dong, Munchang-dong, and Jeongnim-dong, emerge as

structurally high-risk areas with both elevated mean PM10/PM2.5 levels and high shares of high-concentration hours. At the broader scale, the eastern sector of Daejeon (Dong-gu, Jung-gu, and Daedeok-gu) exhibits generally higher mean concentrations and high-episode shares than the western sector (Seo-gu and Yuseong-gu).

For near-future analysis, we construct a set of multi-analog scenarios (Scenarios A/B/C) by treating each of 2021, 2022, and 2023 as a plausible pattern for 2026, and use the trained RF/XGBoost models to predict PM10 and PM2.5 distributions in 2026. We then compute, across the three scenarios, two models, and two pollutants, ensemble high-episode frequencies and the number of occurrences of high-risk classes. Under the PM2.5 criterion, all urban air-monitoring stations are classified as high-risk from an ensemble perspective, whereas no station is classified as high-risk under the PM10 criterion. This suggests that the Daejeon urban monitoring network is structurally exposed to a high level of risk in terms of PM2.5.

This study is significant in that it links one-hour-ahead PM10/PM2.5 prediction, current (2021–2023) spatial vulnerability, and a 2026 multi-analog near-future scenario within a reproducible data, modeling, and spatial-analysis pipeline based solely on public monitoring data. Furthermore, by jointly considering PM10 and PM2.5 in vulnerability metrics and ensemble risk classification at the administrative-dong and East/West sector levels, the framework provides a practical basis for identifying priority management zones in urban air-quality policy, refining local alert systems, and supporting subsequent work that couples with physical air-quality models or extends to climate and emission scenarios.

Key words: PM10; PM2.5; short-term forecasting; spatial vulnerability; scenario analysis; Daejeon; machine learning; QGIS; Power BI; public data